

```
!pip install pyLDAvis -qq
!pip install -qq -U gensim
!pip install spacy -qq
!pip install matplotlib -qq
!pip install seaborn -qq
```

```
import pandas as pd
import spacy
import seaborn as sns
sns.set()
import spacy
import pyLDAvis.gensim_models
pyLDAvis.enable_notebook()# Visualise inside a notebook
import en_core_web_md
from gensim.corpora.dictionary import Dictionary
from gensim.models import LdaMulticore
from gensim.models import CoherenceModel
```

C:\Users\Vaishali\anaconda3\lib\site-packages\scipy\sparse\sparsetools.py:21: DeprecationWarning: `scipy.sparse.sparsetools` is deprecated and will be removed in a future version. The functionality has been moved to the `scipy.sparse` module.
scipy.sparse.sparsetools is a private module for scipy.sparse, and should not be used.
_deprecated()

```
reports = pd.read_csv("../FYP/processed_data.csv")
reports.head()
```

	news_date	tokens
0	1/6/2011 2:45:49 PM	நாலு,ஆள்,உயரம்,முறுக்கு,மீசை,கையில்,வீச்சரிவாள...
1	1/6/2011 2:56:51 PM	அமானுஷ்யமான,சம்பவம்,நம்,சுற்றி,ஆங்காங்கே,நட,கொ...
2	1/6/2011 3:02:00 PM	காமன்வெல்த்,போட்டி,ஏற்பாட்டில்,நடைபெறு,முறைகேட...
3	1/6/2011 3:08:15 PM	தென்அமெரிக்க,நாடான,பெருவில்,காடுகள்,பயங்கரமானவ...
4	1/6/2011 3:09:20 PM	கடந்த,ம்,தேதி,சாயங்காலம்,அடைமழையை,கிழித்தபடி,ச...

```
reports.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 126746 entries, 0 to 126745
Data columns (total 2 columns):
#   Column      Non-Null Count  Dtype
---  ---
0    news_date  126746 non-null  object
1    tokens     126746 non-null  object
dtypes: object(2)
memory usage: 1.9+ MB
```

```
reports["tokens"] = reports["tokens"].map(lambda x: x.split(","))
reports.head()
```

	news_date	tokens
0	1/6/2011 2:45:49 PM	[நாலு, ஆள், உயரம், முறுக்கு, மீசை, கையில், வீச...
1	1/6/2011 2:56:51 PM	[அமானுஷ்யமான, சம்பவம், நம், சுற்றி, ஆங்காங்கே,...
2	1/6/2011 3:02:00 PM	[காமன்வெல்த், போட்டி, ஏற்பாட்டில், நடைபெறு, மு...
3	1/6/2011 3:08:15 PM	[தென்அமெரிக்க, நாடான, பெருவில், காடுகள், பயங்க...
4	1/6/2011 3:09:20 PM	[கடந்த, ம், தேதி, சாயங்காலம், அடைமழையை, கிழித்...

```
len(reports)
```

```
126746
```

```
from gensim import corpora
```

```
text_data = reports["tokens"]
dictionary = corpora.Dictionary(text_data)
dictionary.filter_extremes(no_below=5, no_above=0.5, keep_n=1000)
corpus = [dictionary.doc2bow(text) for text in text_data]
```

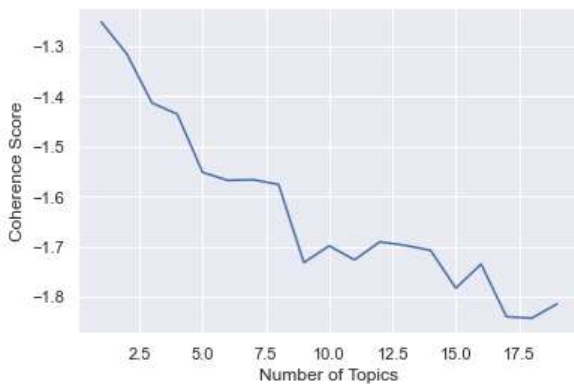
```
lda_model = LdaMulticore(corpus=corpus, id2word=dictionary, iterations=50, num_topics=10, workers = 4, passes=10)
```

```
topics = []
score = []
```

```
#C_umass score
```

```
for i in range(1,20,1):
    lda_model = LdaMulticore(corpus=corpus, id2word=dictionary, iterations=10, num_topics=i, workers = 4, passes=10, random_state=
    cm = CoherenceModel(model=lda_model, corpus=corpus, dictionary=dictionary, coherence='u_mass')
    topics.append(i)
    score.append(cm.get_coherence())
```

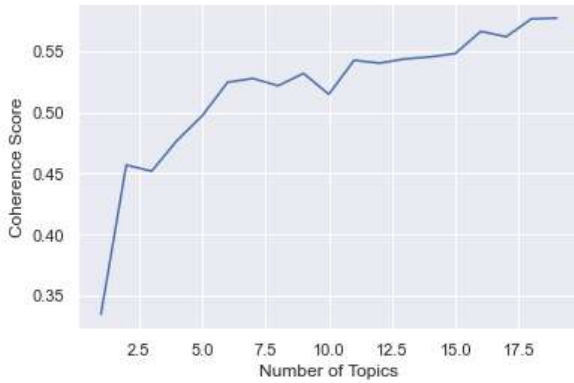
```
import matplotlib.pyplot as plt
plt.plot(topics, score)
plt.xlabel('Number of Topics')
plt.ylabel('Coherence Score')
plt.show()
```



```
#C_v score
```

```
topics = []
score = []
for i in range(1,20,1):
    lda_model = LdaMulticore(corpus=corpus, id2word=dictionary, iterations=10, num_topics=i, workers = 4, passes=10, random_state=
    cm = CoherenceModel(model=lda_model, texts = reports['tokens'], corpus=corpus, dictionary=dictionary, coherence='c_v')
    topics.append(i)
    score.append(cm.get_coherence())
```

```
plt.plot(topics, score)
plt.xlabel('Number of Topics')
plt.ylabel('Coherence Score')
plt.show()
```



```
lda_model = LdaMulticore(corpus=corpus, id2word=dictionary, iterations=100, num_topics=7, workers = 4, passes=100)
```

```
lda_model.print_topics(-1)
```

```
[(0,
 '0.024*"வரு" + 0.021*"பகுதி" + 0.019*"மக்கள்" + 0.019*"மணி" + 0.017*"செல்" + 0.015*"மாவட்டம்" + 0.015*"சென்னை" + 0.015*"காலை"',
 (1,
 '0.041*"போலீசார்" + 0.028*"வா" + 0.028*"சேர்" + 0.019*"செல்" + 0.015*"விசாரணை" + 0.014*"நேற்று" + 0.014*"கைது" + 0.014*"ருகே"',
 (2,
 '0.034*"ரு" + 0.029*"ம்" + 0.028*"அரசு" + 0.018*"வேண்டு" + 0.017*"வழக்கு" + 0.016*"தேதி" + 0.015*"ஆண்டு" + 0.015*"கடந்
 (3,
 '0.019*"வேண்டு" + 0.017*"ஆனால்" + 0.016*"வா" + 0.015*"இல்" + 0.015*"படம்" + 0.015*"படத்தில்" + 0.014*"கூறு" + 0.012*"த
 (4,
 '0.030*"அரசு" + 0.028*"மத்திய" + 0.024*"வரு" + 0.018*"வேண்டு" + 0.016*"நடத்து" + 0.015*"இந்தியா" + 0.014*"நாடு" + 0.014*"குறி"',
 (5,
 '0.042*"தேர்தல்" + 0.038*"தலைவர்" + 0.029*"கட்சி" + 0.023*"காங்கிரஸ்" + 0.023*"மாவட்டம்" + 0.021*"திமுக" + 0.020*"பாஜ'
 + 0.017*"அதிமுக"',
 (6,
 '0.051*"இந்தியா" + 0.046*"அணி" + 0.041*"போட்டி" + 0.031*"வது" + 0.030*"வீரர்" + 0.020*"வெற்றி" + 0.018*"கிரிக்கெட்" + 0
```

```
lda_model[corpus][0]
```

```
[(0, 0.48286268), (1, 0.35839072), (3, 0.14729519)]
```

```
lda_display = pyLDavis.gensim_models.prepare(lda_model, corpus, dictionary)
pyLDavis.display(lda_display)
```

C:\Users\Vaishali\anaconda3\lib\site-packages\pyLDavis_prepare.py:243: FutureWarning: In a future version of pandas all argument 'labels' will be keyword-only
default_term_info = default_term_info.sort_values(

